

PREDICȚIE ABANDON UNIVERSITAR

Documentație proiect
Machine Learning

Student: Libotean Bogdan

2026

Cuprins

1	Introducere și Motivație	2
1.1	Context și importanță	2
2	Descrierea Datelor și Contextul Proiectului	3
2.1	Setul de date	3
2.2	Definirea problemei de Machine Learning	5
3	State-of-the-Art	6
3.1	Fundamente teoretice ale algoritmilor utilizați	6
3.1.1	Logistic Regression	6
3.1.2	Support Vector Machines	6
3.1.3	Random Forest	6
3.1.4	XGBoost (Extreme Gradient Boosting)	6
4	Implementarea	7
4.1	Încărcarea și explorarea datelor	7
4.1.1	Curățarea și preprocesarea datelor	7
4.1.2	Analiza outlierilor	8
4.1.3	Feature Engineering	8
4.1.4	Analiza importanței caracteristicilor	9
4.2	Selecția algoritmilor și argumentarea alegerii	9
4.2.1	Logistic Regression	9
4.2.2	Random Forest	9
4.2.3	XGBoost	10
4.2.4	Support Vector Machine (SVM)	10
4.3	Împărțirea datelor (Training, Validation, Test)	10
4.4	Optimizarea hiperparametrilor	10
5	Testare și Validare	11
5.1	Metrici de evaluare utilizate	11
5.2	Analiza comparativă a modelelor	11
6	Rezultate și Discuții	15
6.1	Performanța modelului final	15
6.2	Analiza erorilor și cazuri limită	15
6.3	Explicabilitatea modelului (Model Explainability)	16
6.3.1	Analiza coeficienților	16
6.3.2	Shapley Values	17
6.3.3	Validarea prin Permutation Importance	18
7	Concluzii și Cunoștințe Noi	19
7.1	Lecții învățate	19
7.2	Limitări și direcții viitoare de dezvoltare	19

1. Introducere și Motivație

1.1. Context și importanță

Abandonul universitar reprezintă o provocare cu care se confruntă sistemele de învățământ superior în prezent. Atunci când un student renunță la studii, impactul este resimțit pe mai multe niveluri: instituțiile pierd resurse, societatea pierde capital uman calificat, iar tinerii își văd afectate oportunitățile profesionale și parcursul personal.

Aspectul trist al problemei este că, în mod tradițional universitățile analizau abandonul prin statistici retrospective, adică abia după ce fenomenul s-a petrecut. Prin utilizarea tehnicilor de Machine Learning, se creează oportunitatea de a schimba aceasta abordare prin folosirea datelor istorice pentru a construi modele predictive care sunt capabile să identifice din timp studenții aflați în situație de risc, așa cum se evidențiază în studiile recente de specialitate [4].

S-a abordat această problemă datorită complexității ei umane și sociale. Abandonul nu este determinat de un singur factor, el este rezultatul unei interacțiuni complexe între situația financiară a familiei, suportul social, adaptarea la mediul universitar și performanța școlară din primele luni, aspect analizat pe larg în literatura de management educațional [5]. Rezultatele unui astfel de model pot fi integrate în platformele universitare pentru a trimite alerte automate către departamentele de consiliere, permițând acordarea de burse, sprijin psihologic sau meditații personalizate exact celor care au cea mai mare nevoie.

2. Descrierea Datelor și Contextul Proiectului

2.1. Setul de date

Sistemul predictiv dezvoltat în acest proiect are la bază setul de date public „Student Dropout Prediction Dataset”, disponibil pe platforma Kaggle. Acest set de date a fost generat pentru a simula un mediu universitar și cuprinde un eșantion robust de 10.000 de înregistrări și 20 de coloane care surprind diverse aspecte din viața academică, personală și socio-economică a studenților.

Variabila țintă este reprezentată de coloana binară Dropout și are două valori posibile:

- **0 (Non-Dropout):** indică faptul că studentul a decis să își continue studiile sau a absolvit cu succes. În setul de date, această clasă reprezintă o proporție de 76,46% dintre studenți.
- **1 (Dropout):** indică faptul că studentul a abandonat facultatea. Această clasă reprezintă o proporție de 23,54%.

Aceste rate indică un dataset ușor dezechilibrat. Un model naiv care ar prezice mereu clasa majoritară ar atinge o acuratețe de 76,46% fără a învăța nimic, acest lucru impune utilizarea unor metrice de evaluare mai stricte decât acuratețea, conform recomandărilor metodologice stabilite de [8].

Cele 19 variabile utilizate pentru predicție pot fi grupate în patru categorii principale:

1. Indicatori demografici și socio-economici:

- **Age:** Vârsta studentului, care variază între 17 și 29 ani, cu o medie de 21.
- **Gender:** Sexul studentului, distribuit aproape ideal, cu 50,11% femei.
- **Family_Income:** Venitul anual al familiei.
- **Parental_Education:** Nivelul de educație al părinților (Liceu, Licență, Master, Doctorat).

2. Factori logistici și stil de viață:

- **Internet_Access:** Accesul la internet, esențial pentru învățământul modern.
- **Travel_Time_Minutes:** Timpul pierdut pe drum spre universitate.
- **Partv_Time_Job:** Statutul de angajat part-time al studentului (aproximativ 40% dintre studenți lucrează).
- **Scholarship:** Deținerea unei burse de studii (35,1% dintre studenți beneficiază de bursă).

3. Comportament și performanță academică:

- **Study_Hours_per_Day:** Numărul de ore dedicate zilnic studiului individual.
- **Attendance_Rate:** Rata de prezență la cursuri.
- **Assignment_Delay_Days:** Numărul mediu de zile de întârziere la predarea proiectelor/temelor.
- **GPA, Semester_GPA, CGPA:** Notele medii ale studentului calculate pe diferite intervale (pe o scală de la 0 la 4, specifică sistemului american).
- **Semester:** Anul de studii curent (de la anul 1 până la anul 4).
- **Department:** Facultatea sau profilul urmat (Științe, Inginerie, Business, Arte, Computer Science).

4. Sănătate mentală și bunăstare:

- **Stess_Index:** Un indice de stres pe o scară de la 1 la 10.




Figura 2.1 Corelatii

În urma analizei inițiale de corelație cu variabila țintă Dropout, s-a constatat că cel mai puternic impact negativ îl au indicatorii de performanță academică (GPA: -0,46; Semester_GPA: -0,45; CGPA: -0,44). Aceasta înseamnă că o notă mai mare reduce riscul de abandon. La polul opus, indicele de stres (Stess_Index: +0,26) prezintă o corelație pozitivă semnificativă, sugerând că un nivel ridicat de stres crește probabilitatea ca un student să renunțe la studii.

2.2. Definirea problemei de Machine Learning

Din punct de vedere computațional, problema este formalizată ca o clasificare binară. Obiectivul algoritmilor constă în construirea unei funcții matematice capabile să mapeze vectorul de caracteristici ale unui student către o probabilitate care precizează apartenența sa la clasa 1 (Dropout) sau clasa 0 (Non-Dropout), utilizând metodologiile standard din ecosistemul de analiză a datelor [10].

Scopul nu este doar clasificarea rigidă, ci obținerea unui scor de risc. Prin setarea unui prag de decizie, universitatea poate prioritiza studenții cu un scor de risc ridicat, optimizând resursele departamentelor de asistență socială și consiliere psihologică pentru a preveni activ abandonul înainte ca acesta să aibă loc [9].

3. State-of-the-Art

3.1. Fundamente teoretice ale algoritmilor utilizați

Pentru dezvoltarea problemei de clasificare binară a abandonului universitar, în cadrul acestui proiect au fost selectați, implementați și comparați patru algoritmi: Logistic Regression, Support Vector Machines - SVM, Random Forest și XGBoost. Această selecție acoperă un spectru larg de paradigme de învățare, de la modelele liniare și geometrice, până la ansambluri bazate pe arbori de decizie, fiind implementați prin intermediul pachetului Scikit-Learn [10].

3.1.1. Logistic Regression

Regresia logistică este un model probabilistic de bază pentru clasificarea binară. Algoritmul de bază se bazează pe o funcție liniară, totuși acesta mapează output-ul în intervalul $[0, 1]$ prin intermediul funcției sigmoidă. Antrenarea modelului se realizează prin optimizarea funcției de cost de tip Log-Cross. Deoarece variabila CGPA a fost eliminată pentru a evita multicolaritatea, modelul folosește o regularizare de tip L_2 pentru a controla stabilitatea coeficienților rămași precum GPA [1].

3.1.2. Support Vector Machines

SVM abordează problema dintr-o perspectivă geometrică formalizată de [?]. Obiectivul SVM este de a trasa o linie perfectă care să împartă studenții în două tabere distincte: cei care continuă facultatea și cei care abandonează. Deoarece în realitate comportamentul uman nu poate fi separat printr-o linie dreaptă perfectă, SVM folosește kernel RBF care curbează și adaptează această graniță pentru a se potrivi cu formele complexe ale datelor [10].

3.1.3. Random Forest

Numele acestui algoritm îl descrie perfect deoarece acest algoritm este o colecție formată din foarte mulți arbori de decizie care lucrează în paralel [3]. Un singur arbore de decizie funcționează ca un set de întrebări consecutive. Deoarece un singur arbore poate să greșească ușor, Random Forest creează sute de astfel de arbori, fiecare analizând bucăți diferite de date. La final, decizia pentru clasa Dropout se ia pe baza schemei de vot majoritar a tuturor arborilor [1].

3.1.4. XGBoost (Extreme Gradient Boosting)

XGBoost este tot un algoritm bazat pe arbori de decizie, dar, spre deosebire de Random Forest, unde arborii lucrează deodată, aici sunt construiți pe rând. Primul arbore face o predicție brută, al doilea arbore analizează doar greșelile făcute de primul și încearcă să le repare, al treilea repară greșelile celui de-al doilea și tot așa. Este ca un proces de învățare continuă din greșeli.

4. Implementarea

4.1. Încărcarea și explorarea datelor

Primul pas în proiect a fost încărcarea setului de date de pe Kaggle folosind biblioteca Pandas din Python [10]. Dataset-ul conține 10000 de studenți și 20 de coloane cu informații. S-a observat că 9 dintre coloane din dataset au valori numerice continue, 3 variabile întregi și 8 variabile categoriale de tip text.

Analiza distribuției variabilei țintă a evidențiat existența unui dezechilibru moderat între clase:

- aproximativ 76% dintre studenți aparțin clasei Non-Dropout;
- aproximativ 24% aparțin clasei Dropout.




Figura 4.1 Distribuție dropout

Această observație este importantă deoarece un model care prezice mereu clasa majoritară ar obține acuratețe aparent bună fără să învețe relații reale de date. Din acest motiv, în etapa de evaluare au fost utilizate și alte metrice precum Recall, Precision, F1-score și ROC-AUC.

4.1.1. Curățarea și preprocesarea datelor

Înainte de a trimite datele către algoritmi, au avut nevoie de curățare. Pentru a asigura o curățare riguroasă a datelor, au fost aplicați următorii pași:

1. **Eliminarea cracteristicilor redundante:** S-a decis eliminarea completă a caracteristicilor CGPA și Semester_GPA din matricea de intrare.

Păstrarea acestora ar fi indus o coliniaritate ridicată cu variabila GPA, riscând apariția fenomenului de data leakage. De asemenea au mai fost eliminate următoarele coloane: Student_ID deoarece reprezenta doar un indicator unic fără relevanță predictivă și Unamed: 19 - o coloană inutilă generată la export.

2. **Tratarea valorilor lipsă:** În urma verificării dataset-ului au fost identificate valori lipsă în coloana Family_Income. Acestea au fost completate folosind mediana coloanei.
3. **Encodarea variabilelor categoriale:** Majoritatea algoritmilor necesită date numerice, astfel ca variabilele de tip string au fost transformate prin mai multe metode de encoding.
 - **Binary Encoding:** Variabilele precum Gender, Internet_Access, Part_Time_Job, Scholarship au fost convertite în valori numerice de tip 0 și 1.
 - **Ordinal Encoding:** Variabila Semester conține o relație naturală de ordine între ani de studiu. Din acest motiv a fost aplicată o mapare ordinală (Year 1 - 0, Year 2 - 1, Year 3 - 2, Year 4 - 3)
 - **One-Hot Encoding:** Pentru variabilele nominale fără ordine naturală: Departament și Parental_Education s-a utilizat tehnica One-Hot Encoding prin funcția `pd.get_dummies()`. Această metodă previne introducerea unor relații artificiale între categorii.

4.1.2. Analiza outlierilor

În cadrul analizei exploratorii au fost investigate și valorile extreme pentru variabila Study_Hours_per_Day folosind metoda IQR (Interquartile Range).

Au fost identificați 86 de outlieri, reprezentând aproximativ 0,85% din întregul dataset. Deoarece proporția lor este foarte redusă și valorile respective pot reflecta situații reale, s-a decis păstrarea lor în dataset.

4.1.3. Feature Engineering

Pentru a îmbunătăți capacitatea modelelor de a identifica relații complexe dintre variabile, au fost create caracteristici noi.

- **study_efficiency** este prima caracteristică creată cu următoarea formulă: $study_efficiency = GPA / Study_Hours_per_Day$. Scopul acestei variabile este de a măsura eficiența procesului de învățare, nu doar cantitatea de timp investită.
- **risk_score** a fost a doua caracteristică, având următoarea formulă: $risk_score = Stress_Index + Assignment_Delay_Days - Attendance_Rate / 10$. Aceasta combină nivelul de stres, întârzierile la predarea temelor și prezența la cursuri.

4.1.4. Analiza importanței caracteristicilor

Pentru a identifica cele mai relevante variabile din dataset a fost utilizat un model Random Forest Classifier.

Analiza importanței caracteristicilor a confirmat faptul că variabilele academice au cea mai mare influență asupra predicției abandonului.




Figura 4.2 Importanța caracteristicilor

4.2. Selecția algoritmilor și argumentarea alegerii

Pentru rezolvarea problemei de clasificare binară a abandonului universitar au fost selectați patru algoritmi diferiți, fiecare abordând problema dintr-o perspectivă matematică distinctă [4]. Pe lângă modelele individuale au fost testate și tehnici de ensemble learning (Voting Classifier și Stacking Classifier).

4.2.1. Logistic Regression

Acest model a fost ales ca model de bază deoarece are o interpretabilitate ridicată, viteză de antrenare și capacități de a produce probabilități ușor de interpretat.

4.2.2. Random Forest

Random Forest a fost selectat pentru capacitatea sa de a modela relații neliniare și interacțiuni complexe între statistici. Avantajele principale sunt: reducerea riscului de overfitting și posibilitatea calculării importanței caracteristicilor.

4.2.3. XGBoost

XGBoost a fost inclus datorită performanțelor excelente raportate în literatura de specialitate pentru date tabulare. Modelul este capabil să învețe relații complexe dintre variabile și să optimizeze iterativ greșelile făcute de arborii anteriori. De asemenea XGBoost pune la dispoziție mecanisme eficiente pentru gestionarea dezechilibrului dintre clase.

4.2.4. Support Vector Machine (SVM)

SVM a fost utilizat pentru capacitatea sa de a construi frontiere de decizie complexe prin utilizarea kernel-ului RBF. Acest model este eficient în problemele unde clasele nu pot fi separate liniar și poate obține performanțe foarte bune în spații multidimensionale.

4.3. Împărțirea datelor (Training, Validation, Test)

După finalizarea preprocesării, dataset-ul a fost împărțit în subseturi utilizate pentru antrenare, validare și testare. Împărțirea datelor a fost realizată cu funcția *train_test_split()* din biblioteca Scikit-Learn.

A fost aplicată stratificarea pentru a păstra aceeași proporție a claselor Dropout și Non-Dropout în toate subseturile.

Pentru algoritmi sensibili la scară, precum Logistic Regression și SVM, a fost aplicată standardizarea caracteristicilor utilizând *StandardScaler*. Standardizarea transformă variabilele astfel încât acestea să aibă media aproximativ 0 și deviația standard aproximativ 1.

4.4. Optimizarea hiperparametrilor

Ca un algoritm să fie performant are nevoie de o configurare corectă a hiperparametrilor. S-a optat pentru automatizarea acestui proces utilizând tehnica de *GridSearchCV* și *RandomizedSearchCV* puse la dispoziție de biblioteca Scikit-Learn [10].

Pentru modelul **Random Forest**, spațiul de căutare a inclus numărul de estimatori, adâncimea maximă a arborilor și numărul minim de mostre pentru divizarea unui nod. În cazul **XGBoost**, s-a pus accent pe optimizarea ratei de învățare, a parametrului de regularizare și adâncimea arborilor, cu scopul de a preveni overfitting-ul [2].

Toate evaluările din timpul căutării s-au realizat folosind metoda *Cross-Validation* cu 5 pliuri. Această abordare asigură că modelul este validat pe subseturi diferite de date, obținându-se astfel o estimare robustă a performanței generale.

5. Testare și Validare

5.1. Metrici de evaluare utilizate

Pentru evaluarea performanței algoritmilor de clasificare au fost utilizate mai multe metrice specifice problemelor de clasificare binară. Alegerea acestora este justificată de faptul că dataset-ul utilizat este dezechilibrat, clasa Non-Dropout fiind semnificativ mai numeroasă decât clasa Dropout.

În astfel de situații, utilizarea exclusivă a metricii Accuracy poate conduce la concluzii greșite, deoarece un model obține o acuratețe ridicată fără să identifice eficient studenții aflați în risc.

- **Accuracy** - reprezintă proporția totală de predicții corecte raportată la numărul total de exemple evaluate. Această metrică oferă o imagine generală asupra performanței modelului, însă reflectă întotdeauna capacitatea reală de identificare a clasei minoritare.
- **Precision** - aceasta măsoară cât de corecte sunt predicțiile pozitive realizate de model. În contextul proiectului, Precision indică procentul studenților clasificați ca fiind predispuși abandonului și chiar au abandonat. Un Precision ridicat reduce numărul alarmelor false și contribuie la utilizarea eficientă a resurselor universitare.
- **Recall** - reprezintă capacitatea modelului de a identifica studenții aflați în risc de abandon. Aceasta este una dintre cele mai importante metrice deoarece obiectivul principal este detectarea timpurie a studenților vulnerabili. Un Recall ridicat înseamnă că sistemul reușește să identifice majoritatea studenților care riscă să abandoneze facultatea.
- **F1-Score** - reprezintă media armonică dintre Precision și Recall și oferă o evaluare echilibrată a modelului. Este o metrică utilă deoarece penalizează modelele care obțin performanțe bune doar pe una dintre cele două metrice.
- **ROC-AUC** - măsoară capacitatea modelului de a separa cele două clase indiferent de pragul de clasificare ales. O valoare apropiată de 1 indică o separare foarte bună între studenții care abandonează și cei care își continuă studiile.

5.2. Analiza comparativă a modelelor

După optimizarea hiperparametrilor, performanțele modelelor au fost comparate utilizând toate metricile prezentate anterior. După cum s-a menționat și mai sus, datasetul este ușor dezechilibrat de aceea evaluarea modelelor nu s-a limitat la Acuratețe. În contextul prevenirii abandonului universitar, obiectivul principal este obținerea unui Recall mare pentru a identifica din timp studenții aflați la risc.

În graficul de mai jos, se pot observa rezultatele tuturor modelelor antrenate și toate ensembles create. Vom discuta mai amanunțit despre rezultatele modelelor de bază: Logistic Regression, Random Forest, XGBoost, SVM.




Figura 5.1 Comparație modele

1. **Logistic Regression (Modelul recomandat):** Deși înregistrează o acuratețe de 74,20%, acest model liniar oferă cel mai comportament pentru această problemă. El obține cel mai ridicat **Recall (76,43%)** și cea mai mare valoare pentru **ROC-AUC (81,98%)**. Acest lucru demonstrează o capacitate bună de discriminare între clase și garantează că peste 76% din totalul studenților reali care vor abandona sunt corect detectați de model. Scorul F1 maxim de 58,25% confirmă că acest model este superior în fața celorlalți.




Figura 5.2 Matrice de confuzie - Logistic Regression

2. **Random Forest:** Acest algoritm obține cea mai mare **Acuratețe (77,90%)** și cea mai bună **Precizie (52,48%)** dintre toate modelele testate. Cu toate acestea, din cauza structurii sale, prezintă un Recall foarte scăzut (56,26%). Pentru o aplicație practică de prevenire a abandonului, acest comportament este sever penalizat: modelul tinde să fie prea conservator și ratează aproape jumătate din numărul studenților expuși abandonului.




Figura 5.3 Matrice de confuzie - Random Forest

3. **Support Vector Machine (SVM):** Modelul SVM oferă o performanță foarte apropiată de variantele bazate pe boosting, cu un **Recall solid de 72,82%** și o valoare **ROC-AUC de 80,45%**. Totuși, se constată o ușoară degradare a acurateții globale și a preciziei, astfel clasându-se sub Logistic Regression și XGBoost în ceea ce privește stabilitatea predicțiilor.




Figura 5.4 Matrice de confuzie - SVM

4. **XGBoost:** Algoritmul bazat pe Gradient Boosting a obținut o performanță aproape identică cu Logistic Regression în privința acurateții și un **Recall solid de 73,89%**. Cu toate acestea, coeficienții Logistic Regression au rămas mai buni pe F1-Score și pe aria de sub curba ROC.




Figura 5.5 Matrice de confuzie - XGBoost

6. Rezultate și Discuții

6.1. Performanța modelului final

În urma etapei de comparare a algoritmilor, Logistic Regression a fost selectată drept modelul final pentru predicția abandonului școlar. Această decizie a fost făcută datorită capacității superioare a modelului de a identifica studenții aflați în situație de risc.

Pentru a înțelege mai profund comportamentul modelului pe setul de date de test, se analizează matricea de confuzie din Figura 5.2:

1. **Adevărat Negativi (TN):** 1132 studenți au fost clasificați corect ca fiind stabili.
2. **Fals Pozitivi (FP):** 397 de studenți stabili au fost etichetați eronat ca fiind predispuși la abandon.
3. **Fals Negativi (FN):** 111 studenți care au abandonat real studiile au fost ratați de model.
4. **Adevărat Pozitivi (TP):** 360 de studenți au fost identificați corect în categoria de risc de abandon.

Rezumatul metricilor statistice obținute pe setul de test este detaliat în tabelul de mai jos:

Tabela 6.1 Metricile de performanță ale modelului final (Logistic Regression)

Metrică	Valoare Obținută	Semnificație în Contextul Problemei
Acuratețe	74.60%	Proporția totală a predicțiilor corecte (clasa 0 și clasa 1).
Precizie	47.56%	Din totalul studenților alertați, câți se află în abandon real.
Recall	76.43%	Proporția de studenți la risc detectați cu succes din totalul celor care abandonează.
F1-Score	58.63%	Media armonică între precizie și recall, indicatorul de echilibru al modelului.
ROC-AUC	82.00%	Capacitatea globală a modelului de a diferenția un student stabil de unul la risc.

6.2. Analiza erorilor și cazuri limită

Niciun model de învățare automată nu este perfect, iar analiza calitativă a zonelor în care algoritmul eșuează este esențială pentru înțelegerea limitărilor sale. În cazul acesta, erorile se împart în două categorii:

1. Erorile de tip Fals Pozitiv

- Modelul prezice că studentul va abandona, dar în realitate acesta își continuă studiile.
- Analiza profilelor din această categorie arată că acești studenți prezintă indicatori asociați cu abandonul: medii mici în primul semestru sau absențe.
- Acest tip de eroare este considerat tolerabil. În cel mai rău caz, universitatea va alocă resurse preventive unui student care nu avea strictă nevoie, dar aceasta nu îi afectează negativ parcursul.

2. Erorile de tip Fals Negativ

- Modelul prezice că studentul este stabil, dar acesta abandonează.
- Aceasta este cea mai periculoasă eroare. Ea apare la studenții care, din punct de vedere academic și financiar, au profil stabil. Totuși aceștia aleg să abandoneze.
- Acest tip de eroare este critic, deoarece acești studenți rămân invizibili pe radarul preventiv al instituției. Pentru prevenirea acestor erori sau măcar diminuarea lor, ar fi necesară colectarea unor date de natură psihologică sau chestionare care vizează descoperirea nivelului de satisfacție al studenților.

6.3. Explicabilitatea modelului (Model Explainability)

Pentru a asigura transparența decizională, s-au aplicat trei tehnici de interpretare a modelului: analiza coeficienților, valorile SHAP și Permutation Importance.

6.3.1. Analiza coeficienților

Coeficienții extrași direct din model reprezintă impactul fiecărei variabile asupra abandonului. Un coeficient pozitiv crește riscul de abandon, în timp ce unul negativ indică un factor de protecție.

- Factori de risc major: Variabila *risk_score* și *Stress_Index* prezintă cele mai mari valori pozitive. Aceasta înseamnă că un nivel ridicat de stress, neglijarea sarcinilor și prezența slabă sunt primii predictorii care împing studentul spre abandon.
- Factori de protecție: Performanța academică (*GPA*) și *study_efficiency* au coeficienți negativi puternici. Aceștia acționează precum o ancoră: cu cât notele sunt mai mari, cu atât probabilitatea de abandon scade exponențial.




Figura 6.1 Analiza coeficienților

6.3.2. Shapley Values

Tehnica SHAP oferă o interpretare avansată bazată pe teoria jocurilor, distribuind meritul fiecărei caracteristici pentru predicția finală.




Figura 6.2 SHAP - Importanța globală a features

6.3.3. Validarea prin Permutation Importance

Pentru a elimina eventualele distorsiuni ale modelelor liniare, s-a aplicat tehnica Permutation Importance, care evaluează degradarea directă a F1-score pe setul de test atunci când valorile unei caracteristici sunt amestecate aleatoriu. Rezultatele sunt redată în Figura 6.3




Figura 6.3 Permutation Importance

Conform analizei de permutare, eliminarea structurii din variabila *GPA* cauzează cea mai mare scădere a scorului F1, urmată aproape de *study_efficiency*. Această triplă convergență demonstrează că performanța academică și starea de echilibru psihologic sunt factorii cei mai importanți de prezicere a abandonului.

7. Concluzii și Cunoștințe Noi

7.1. Lecții învățate

Dezvoltarea acestui proiect de predicție a abandonului școlar a oferit o serie de perspective valoroase, atât din punct de vedere tehnic, cât și din perspectiva aplicativă.

- **Importanța critică a preprocesării și calității datelor:** Faza inițială de analiză a demonstrat că algoritmi depind de un pipeline riguros de date. Gestionarea corectă a variabilelor categorice prin tehnici de encoding și aducerea variabilelor numerice la aceeași scară reprezintă un pas vital pentru stabilitatea modelelor liniare.
- **Acuratețea poate fi o metrică înșelătoare:** Întrucât setul de date utilizat a prezentat un dezechilibru între clase, proiectul a evidențiat de ce *Accuracy* nu trebuie folosit ca indicator unic.

7.2. Limitări și direcții viitoare de dezvoltare

Deși modelul final prezintă o putere de clasificare stabilă, au fost identificate câteva limitări:

- **Natura statică a datelor:** Setul de date analizează studenții pe baza unui istoric fix. În realitate, abandonul universitar este un proces care evoluează în timp. Modelul actual nu poate capta fluctuațiile comportamentale de la o săptămână la alta.
- **Absența unor metrice calitative:** Indicatori precum *Stress_Index* ajută modelul, dar sunt dificil de colectat cu precizie în viața reală fără chestionare constante. Lipsesc din analiza actuală date de ordin calitativ esențiale: nivelul de integrare socială, probleme severe de sănătate sau detalii de dinamică familială.
- **Dependța de contextul instituției:** Modelul a fost antrenat pe structura acestui set de date, specific sistemului american, de 10000 de înregistrări. Diferențele majore dintre țări, dintre facultăți pot reduce semnificativ capacitatea de generalizare a algoritmului.

Cât despre îmbunătățiri viitoare pentru a adresa limitările identificate și pentru a crește utilitatea sistemului, se propune următoarea:

- **Implementarea unei abordări bazare pe serii temporale:** Transformarea modelului din unul static în unul dinamic, prin utilizarea unor rețele neuronale (LSTM). Astfel, datele de prezență și notele ar putea fi evaluate săptămânal, emițând alerte în timp real în momentul în care comportamentul unui student devine descendent.

Bibliografie

- [1] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer-Verlag, 2009.
- [2] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785-794.
- [3] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [4] C. Rovira, D. Conati, and P. G. Rossi, "Predicting academic dropout through machine learning: A systematic review," *Computers & Education*, vol. 112, pp. 110-125, 2017.
- [5] A. Marquez-Vera, C. R. Morales, and S. V. Soto, "Early dropout prediction using data mining: a case study with high school students," *Expert Systems*, vol. 33, no. 1, pp. 107-124, 2016.
- [6] R. Asif, A. Merceron, S. A. Ali, and N. G. Haider, "Analyzing undergraduate students' performance using data mining techniques," *Journal of Computer Languages, Systems & Structures*, vol. 48, pp. 49-63, 2017.
- [7] S. M. Lundberg and S. I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, pp. 4765-4774. *
- [8] D. Delen, "A comparative analysis of machine learning techniques for student retention," *Expert Systems with Applications*, vol. 37, no. 6, pp. 4396-4403, 2010.
- [9] S. Ameri, M. J. Fard, R. B. Chinnam, and C. Reddy, "Survival analysis for predicting student dropout," in *Proceedings of the IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 2016, pp. 520-529.
- [10] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.